



**WYDZIAŁ FIZYKI
i INFORMATYKI STOSOWANEJ**
Uniwersytet Łódzki

Maciej Bujalski

Kierunek: informatyka

Specjalność: informatyka stosowana

Specjalizacja: aplikacje mobilne

Numer albumu: 386012

Rotacyjnie inwariantne sieci neuronowe

Praca magisterska

wykonana pod kierunkiem
dr Krzysztofa Podlaskiego
w Katedrze Systemów
Inteligentnych, WFiIS UŁ

Łódź 2025

CEL PRACY

Powszechne konwolucyjne sieci neuronowe mają własności analizy obrazu z zachowaniem niezmienniczości ze względu na translacje. Niestety brak w tej chwili uznanych architektur pozwalających na rotacyjną inwariantność. Celem pracy jest analiza efektywności nowych rozwiązań proponowanych w literaturze ze względu na operacje rotacji (np.: <https://arxiv.org/pdf/2007.10588.pdf>). Zadaniem dyplomanta będzie na podstawie istniejącego zbioru uczącego (zdjęć, znaków drogowych lub literek) zbudowanie nowego wzbogaconego o ich różnorakie rotacje. Zaimplementowanie nowych architektur w pytorch lub tensorflow, a następnie przeanalizowanie ich efektywności na wzbogaconym zbiorze obrazów. Wyniki nowej architektury należy porównać do efektywności standardowych sieci konwolucyjnych.

OPIS PRACY

Praca magisterska wykorzystuje zaawansowane technologie i narzędzia wspierające badania nad rotacyjnie inwariantnymi sieciami neuronowymi oraz ich zastosowanie w przetwarzaniu obrazów. W realizacji projektu zostaną zastosowane następujące technologie:

- Język programowania Python – podstawowe narzędzie do implementacji algorytmów i obsługi frameworków uczenia maszynowego dzięki jego wszechstronności i bogatemu ekosystemowi bibliotek, takich jak PyTorch i TensorFlow.
- Frameworki uczenia maszynowego:
 - PyTorch – elastyczny framework umożliwiający szybkie prototypowanie oraz trenowanie sieci neuronowych.
 - TensorFlow – kompleksowe narzędzie do budowy, trenowania i wdrażania modeli uczenia maszynowego.
 - Rotacyjnie inwariantne architektury sieci neuronowych – analiza nowych rozwiązań badanych w literaturze naukowej, takich jak te opisane w publikacji „General E(2)-Equivariant Steerable CNNs”.
- Wykorzystanie akceleracji GPU (np. NVIDIA) – obliczenia zostaną przyspieszone dzięki zastosowaniu kart graficznych NVIDIA, które zapewniają wydajne środowisko dla intensywnych obliczeniowo operacji związanych z uczeniem głębokim. Frameworki takie jak PyTorch i TensorFlow wspierają CUDA, co umożliwia efektywne wykorzystanie GPU.
- Konteneryzacja za pomocą Docker – narzędzie do tworzenia odizolowanych środowisk uruchomieniowych, które zapewni łatwość replikacji środowiska i współdzielenia projektu, również z obsługą GPU.